

Aplicação de Técnica de Aumento de Dados baseada em Redes Adversariais Generativas para Modelos de Qualidade de Água

Relatório Final

Dannylo Cardoso Mauricio ✉
Centro Federal de Educação Tecnológica
Celso Suckow da Fonseca CEFET-RJ

Rafael Sanches ✉
Centro Federal de Educação Tecnológica
Celso Suckow da Fonseca CEFET-RJ

Diego Nunes Brandão ✉
Centro Federal de Educação Tecnológica
Celso Suckow da Fonseca CEFET-RJ

Resumo

Os ecossistemas aquáticos, em especial os ambientes costeiros como praias, canais, lagoas e estuários, possuem elevada relevância ecológica, social e econômica. Contudo, processos de urbanização desordenada, lançamento de efluentes e alterações no uso do solo vêm comprometendo a qualidade da água e a estabilidade desses sistemas. Nesse contexto, torna-se essencial o desenvolvimento de estratégias avançadas de monitoramento e modelagem, capazes de subsidiar políticas de gestão ambiental mais eficazes e sustentáveis. Este trabalho investiga a qualidade da água no Sistema Lagunar de Jacarepaguá, localizado na Zona Oeste do município do Rio de Janeiro (RJ), por meio do emprego de técnicas de inteligência computacional. O estudo analisa dados observacionais históricos (2012–2022) e avalia o potencial de modelos baseados em *Generative Adversarial Networks* (GANs) para a geração de dados sintéticos. A utilização dessa abordagem busca mitigar lacunas e discontinuidades nas séries temporais, ampliando a disponibilidade de dados para análises ambientais. Os resultados obtidos reforçam a viabilidade do uso de GANs como ferramenta de apoio ao monitoramento, contribuindo para a compreensão dos padrões de qualidade da água e para a formulação de estratégias de gestão ambiental mais robustas.

Palavras chave

Qualidade da Água, Redes Adversariais Generativas, Monitoramento Ambiental

Abstract

Aquatic ecosystems, particularly coastal environments such as beaches, channels, lagoons, and estuaries, hold significant ecological, social, and economic importance. However, unplanned urbanization, was-

tewater discharge, and land-use changes have increasingly compromised water quality and the stability of these systems. In this context, the development of advanced monitoring and modeling strategies becomes essential to support more effective and sustainable environmental management policies. This study investigates water quality in the Jacarepaguá Lagoon System, located in the West Zone of Rio de Janeiro (Brazil), through the application of computational intelligence techniques. Historical observational data (2012–2022) were analyzed, and the potential of Generative Adversarial Networks (GANs) was evaluated for generating synthetic data. This approach aims to mitigate gaps and discontinuities in time series, thereby expanding data availability for environmental analyses. The results highlight the feasibility of using GANs as a supporting tool for monitoring, contributing to a better understanding of water quality patterns, and to the formulation of more robust environmental management strategies.

Keywords

Water Quality, Generative Adversarial Networks, Environmental Monitoring

1. Introdução

A preservação da qualidade da água é um dos pilares para a manutenção da vida nos ecossistemas aquáticos e costeiros, além de estar diretamente relacionada ao bem-estar humano e ao cumprimento dos Objetivos de Desenvolvimento Sustentável (ODS), em especial o ODS 6 (Água Potável e Saneamento), o ODS 14 (Vida na Água) e o ODS 11 (Cidades e Comunidades Sustentáveis). No entanto, a urbanização acelerada, o lançamento de efluentes e a ocupação irregular do solo têm comprometido significativa-

mente a saúde desses ambientes, exigindo novas estratégias de monitoramento e gestão.

O Sistema Lagunar de Jacarepaguá (RJ) representa um exemplo emblemático dessa realidade: um conjunto de quatro lagoas costeiras que desempenham funções ecológicas e sociais essenciais, mas que vêm sofrendo forte degradação devido à pressão urbana [Mauricio et al. \(2025\)](#). Apesar do monitoramento realizado por órgãos ambientais, a baixa frequência das coletas e a presença de lacunas temporais dificultam análises contínuas e reduzem a eficiência de políticas de gestão.

Neste contexto, técnicas de inteligência computacional surgem como alternativas para potencializar o monitoramento. Em particular, as Redes Adversariais Generativas (*Generative Adversarial Networks* – GANs) permitem gerar dados sintéticos realistas, capazes de complementar bases observacionais, reduzir a escassez informacional e ampliar a robustez de modelos preditivos [Shashikala et al. \(2025\)](#). Este trabalho investiga a aplicação de GANs na geração de dados sintéticos de qualidade da água no Sistema Lagunar de Jacarepaguá, discutindo resultados, limitações e seu potencial como ferramenta complementar para a gestão ambiental alinhada aos ODS.

O restante deste trabalho está estruturado da seguinte forma: a Seção 2 apresenta uma revisão da literatura sobre uso de GANs para aumento de dados para modelos de qualidade da água. A Seção 3 apresenta uma breve descrição sobre a área de estudo, o processo de coleta de dados e a metodologia utilizada neste trabalho. A Seção 4 apresenta os resultados encontrados pela abordagem adotada. Por fim, a Seção 5 apresenta as considerações finais e perspectivas de trabalhos futuros.

2. Trabalhos Relacionados

O uso de técnicas de aprendizado de máquina para previsão da qualidade da água tem avançado consideravelmente na última década. Diversos estudos exploram modelos supervisionados, como Máquinas de Vetores de Suporte (SVM), Florestas Aleatórias (RF) e Redes Neurais Recorrentes (RNN), aplicados em diferentes contextos ambientais para a previsão de parâmetros como pH, turbidez e oxigênio dissolvido ([Mauricio et al., 2025](#)). Entretanto, a principal limitação enfrentada por esses trabalhos está relacionada à escassez e à irregularidade dos dados coletados, geralmente decorrentes da baixa frequência de monitoramento e de lacunas nas séries temporais.

Nesse cenário, abordagens baseadas em Redes Adversariais Generativas (GANs) surgem como alternativas promissoras para ampliar conjuntos de dados e reduzir a dependência de coletas contínuas. [Zhang et al. \(2020\)](#) aplicaram GANs na reconstrução de campos espaço-temporais de altura do nível do mar no Mar do Norte, demonstrando que modelos generativos podem alcançar resultados comparáveis a filtros de Kalman. Já [Shashikala et al. \(2025\)](#) utilizaram GANs para aumentar dados obtidos por sensores IoT de qualidade da água, como pH, turbidez e sólidos dissolvidos, melhorando a detecção de anomalias e a manutenção preditiva.

Apesar dos avanços, ainda são poucos os trabalhos que exploram sistematicamente o uso de GANs para determinar a qualidade da água em ambientes costeiros. Além disso, muitas pesquisas carecem de detalhamento metodológico e de análises sobre limitações práticas, como complexidade computacional e riscos de sobreajuste. Assim, a literatura aponta um campo em expansão, no qual a integração entre GANs e modelos preditivos tradicionais pode oferecer novas perspectivas para o monitoramento ambiental.

3. Materiais e Métodos

O presente estudo trata de uma pesquisa de natureza quantitativa - por ser fundamentada na análise de dados numéricos - baseada em objetivos descritivos, isto é, que busca estabelecer relações entre variáveis por meio de informações já existentes sobre um determinado tópico ([Gil, 2002](#)).

3.1. Redes Generativas Adversárias (GANs)

As Redes Generativas Adversárias (*Generative Adversarial Networks* – GANs) foram introduzidas por ([Goodfellow et al., 2014](#)) e representam um dos avanços mais significativos em aprendizagem profunda para geração de dados sintéticos. O modelo é composto por duas redes neurais treinadas simultaneamente em um processo competitivo: o gerador (*generator*) e o discriminador (*discriminator*).

O gerador tem como objetivo produzir amostras sintéticas que se aproximem da distribuição dos dados reais. Já o discriminador atua como um classificador binário, buscando distinguir entre amostras reais e amostras produzidas pelo gerador. Durante o treinamento, o gerador tenta enganar o discriminador, enquanto este se aperfeiçoa em identificar falsificações. Esse processo

é formalizado como um jogo de soma zero, baseado na teoria dos jogos, no qual cada rede busca otimizar sua própria função de custo.

A formulação original da GAN pode ser expressa como o seguinte problema de otimização min-max:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (1)$$

em que $p_{data}(x)$ é a distribuição real dos dados, $p_z(z)$ representa a distribuição latente (tipicamente ruído gaussiano ou uniforme), $D(x)$ é a probabilidade atribuída pelo discriminador de que x seja real, e $G(z)$ é a amostra sintética gerada a partir do vetor de ruído z .

As GANs têm sido aplicadas em diversos domínios, como geração de imagens realistas, aumento artificial de bases de dados (*data augmentation*), síntese de áudio e texto, além de aplicações específicas em ciências ambientais e biomédicas (Creswell et al., 2018). Uma das principais vantagens é a capacidade de aprender representações complexas sem a necessidade de uma função de verossimilhança explícita. Contudo, desafios como instabilidade no treinamento, *mode collapse* (colapso de modos) e dificuldade de convergência são recorrentes e motivam o desenvolvimento de variantes como WGAN, LSGAN e CGAN, que buscam maior estabilidade e qualidade na geração de amostras.

No contexto de monitoramento ambiental e qualidade da água, as GANs oferecem potencial para gerar amostras sintéticas que auxiliem na ampliação de conjuntos de dados escassos ou incompletos, preservando características estatísticas relevantes para análises preditivas e regulatórias. Dessa forma, tornam-se uma ferramenta promissora para complementar metodologias tradicionais de coleta e análise de dados.

3.2. Área de Estudo

O Sistema Lagunar de Jacarepaguá é formado por quatro lagoas costeiras interconectadas, localizadas na Zona Oeste do município do Rio de Janeiro, na região da Baixada de Jacarepaguá: Lagoa de Jacarepaguá, Lagoa do Camorim, Lagoa da Tijuca e Lagoa de Marapendi. Sua bacia hidrográfica possui aproximadamente 280 km^2 de área drenante, dos quais cerca de 176 km^2 correspondem às superfícies drenadas pelos rios que deságuam no sistema.

A Lagoa de Jacarepaguá, situada na porção

noroeste, apresenta o segundo maior espelho d'água do conjunto, com cerca de $3,7 \text{ km}^2$. A leste, a Lagoa do Camorim funciona como um canal natural, conectando a Lagoa de Jacarepaguá à Lagoa da Tijuca, sendo a menor componente do sistema. A Lagoa da Tijuca recebe o fluxo hídrico proveniente dessa conexão e escoar em direção ao sul, até o Canal da Joatinga, que estabelece a comunicação com o Oceano Atlântico. Por sua vez, a Lagoa de Marapendi se estende por cerca de 10 km paralelamente à orla do Recreio dos Bandeirantes e da Barra da Tijuca, desembocando na extremidade sul da Lagoa da Tijuca através do Canal de Marapendi (dos Santos, 2014).

O monitoramento da qualidade da água deste complexo lagunar é realizado mensalmente pelo Instituto Estadual do Ambiente (INEA), que mantém oito pontos de coleta distribuídos entre as quatro lagoas. No entanto, apenas seis destes apresentam séries contínuas de observações, sendo, portanto, considerados neste estudo: o ponto 6 na Lagoa de Jacarepaguá; o ponto 5 na Lagoa do Camorim; o ponto 4 na porção central da Lagoa da Tijuca; os pontos 3 e 2 nos extremos oeste e leste da Lagoa de Marapendi; e o ponto 1, próximo à desembocadura do Canal da Joatinga. A Fig. 1 ilustra a localização dos pontos de coleta do INEA no sistema lagunar.

Figura 1: Lagoas e pontos de coleta do SLJP



Fonte: INEA (2013).

3.3. Coleta de Dados

A primeira etapa da pesquisa consistiu na coleta de dados históricos de qualidade da água do Sistema Lagunar de Jacarepaguá (SLJP), disponibilizados pelo Instituto Estadual do Ambiente (INEA). O conjunto de dados, referente ao período de 2012 a 2022, contempla diversos parâmetros físico-químicos e microbiológicos. Devido à elevada taxa de descontinuidade tempo-

ral (intervalos iguais ou superiores a um ano) em parte dos parâmetros, foi necessário um recorte de variáveis visando maximizar o aproveitamento das séries históricas. A Tabela 1 apresenta as variáveis considerados no estudo.

3.4. Método

A metodologia aplicada neste estudo foi estruturada em diferentes etapas, conforme ilustrado no fluxograma da Figura 2. Inicialmente, procedeu-se ao **carregamento dos dados** a partir de um arquivo CSV contendo 480 amostras e 14 variáveis originais. Em seguida, foi realizada a etapa de **limpeza e preparação**, na qual variáveis redundantes foram removidas, resultando em uma base final composta por 13 variáveis.

Posteriormente, efetuou-se a **análise estatística descritiva**, contemplando medidas de tendência central, dispersão e distribuição dos dados. Esta análise permitiu compreender o comportamento das variáveis originais e orientar o desenho da arquitetura de rede adversarial generativa (GAN).

Na sequência, definiu-se a **arquitetura da GAN**, composta por um gerador, responsável por produzir amostras sintéticas com 13 atributos, e por um discriminador, encarregado de avaliar a plausibilidade dessas amostras. O processo de **treinamento da GAN** foi conduzido com 500 épocas e tamanho de lote igual a 16, de modo a refinar iterativamente a qualidade dos dados gerados.

Após o treinamento, a GAN foi utilizada para a **geração de dados sintéticos**, totalizando 100 novas amostras. A qualidade dos dados produzidos foi avaliada por meio de **métricas estatísticas comparativas** (médias, desvios-padrão e distribuições) e pelo **teste de Kolmogorov-Smirnov (KS)**, que possibilitou verificar a aderência entre os conjuntos real e sintético.

Os modelos treinados foram, então, **armazenados em formatos digitais** (.keras e .h5) para uso posterior em tarefas de previsão e classificação. Por fim, procedeu-se à **análise dos resultados**, na qual se discutem os impactos da utilização de dados sintéticos na modelagem da qualidade da água, destacando limitações e potenciais aplicações futuras.




Figura 2: Fluxograma da metodologia: do carregamento/limpeza ao treinamento da GAN, geração, avaliação (KS) e armazenamento dos modelos.

4. Resultados

4.1. Ferramentas Utilizadas

As etapas de processamento e análise dos dados foram implementadas em Python versão 3.12, utilizando diferentes bibliotecas de apoio. A manipulação inicial do conjunto de dados (carregamento do arquivo CSV, limpeza e organização das variáveis) foi realizada com a biblioteca *Pandas*, enquanto operações algébricas e de mani-

Tabela 1: Variáveis utilizadas no treinamento e avaliação da GAN

n	Parâmetro	Abv.	Unidade	Fonte
1	Dia	DIA	–	INEA
2	Mês	MES	–	INEA
3	Ano	ANO	–	INEA
4	Semana do Ano	SEM	–	INEA
5	Dia da Semana	DIASEM	–	INEA
6	Demanda Bioquímica de Oxigênio	DBO	mg/L	INEA
7	Potencial Hidrogeniônico	pH	–	INEA
8	Coliformes Termotolerantes	CT	NMP/100mL	INEA
9	Temperatura da Água	T	°C	INEA
10	Fósforo Total	FT	mg/L	INEA
11	Oxigênio Dissolvido	OD	mg/L	INEA
12	Condutividade	CE	(μ S/cm)	INEA
13	Turbidez	TUR	UNT	INEA

Fonte: Elaborado pelos autores (2024).

pulação matricial contaram com o suporte da *NumPy*. Para o cálculo de estatísticas descritivas e testes de aderência (como o teste de Kolmogorov-Smirnov), empregaram-se as bibliotecas *SciPy* e *Statistics*.

O desenvolvimento e o treinamento da rede adversarial generativa (GAN) foram conduzidos por meio da biblioteca *Keras*, integrada ao *TensorFlow*, possibilitando a construção das arquiteturas do gerador e do discriminador, bem como a realização dos ciclos de treinamento em múltiplas épocas. Recursos adicionais da biblioteca *Scikit-learn* foram empregados para tarefas complementares de avaliação e análise numérica.

Para fins de visualização e interpretação dos resultados, utilizaram-se as bibliotecas *Matplotlib (Pyplot)*, *Seaborn* e *Plotly*, permitindo tanto gráficos exploratórios quanto representações comparativas entre dados reais e sintéticos. O desenvolvimento incremental e a análise preliminar foram realizados em ambiente interativo *Jupyter Notebook*, enquanto os experimentos de treinamento completo foram estruturados em *scripts* dedicados, executados no ambiente de desenvolvimento integrado *Visual Studio Code*.

4.2. Dados, limpeza e estatísticas descritivas

Os dados foram carregados de arquivo CSV e passaram por uma etapa de limpeza que resultou em um conjunto com 480 observações e 13 variáveis numéricas (formato final: 480×13). As variáveis incluem: Dia, Mês, Ano, Semana (Sem), Dia da semana (DiaSem), DBO (mg/L), pH, Coliformes Termotolerantes (NMP/100mL), Tem-

peratura da Água (°C), Fósforo Total (mg/L), OD (mg/L), Condutividade (μ S/cm) e Turbidez (UNT).

As estatísticas descritivas indicam assimetria acentuada em variáveis ambientais críticas. Por exemplo, Coliformes apresentam média de $1,83 \times 10^5$ NMP/100mL e desvio padrão de $3,78 \times 10^5$, com máximo de $1,6 \times 10^6$. A Turbidez (UNT) também é fortemente assimétrica (média 36,9, desvio-padrão 79,0, máximo 1310). Em contraste, pH e Temperatura exibem dispersões moderadas (pH: $\bar{x} = 7,87$, $s = 0,61$; Temperatura: $\bar{x} = 24,65$, $s = 3,19$). Esses padrões sugerem causas longas e múltiplas escalas, o que é relevante para a modelagem generativa.

4.3. Arquitetura e treinamento da GAN

Empregou-se uma GAN totalmente conectada para gerar amostras tabulares condicionadas implicitamente à distribuição observada. O discriminador possui camadas densas com normalização em lote e dropout (parâmetros treináveis $\approx 181,6$ mil), enquanto o gerador contém três blocos densos com normalização e ativações ReLU, culminando em uma saída de 13 dimensões (parâmetros treináveis $\approx 186,0$ mil).

O treinamento foi conduzido por 500 épocas com *batch size* de 16 sobre vetores de dimensão 13 (dados padronizados). Ao longo do treinamento, observou-se redução gradual da função de perda do discriminador (de $\sim 1,18$ para $\sim 1,09$) e estabilização da perda do gerador em torno de 0,68. A acurácia reportada para o discriminador permaneceu próxima de zero, o que, dependendo da implementação da métrica, pode indicar classificação difícil (gerador confundindo o discrimi-

nador) ou métrica não informativa nesse regime; de todo modo, a combinação de perdas sugere treinamento estável, porém sem garantia de *matching* de distribuição em todas as variáveis.

4.4. Geração e avaliação de dados sintéticos

Após o treinamento, foram geradas 100 amostras sintéticas (100×13). A qualidade foi avaliada por estatísticas de resumo e pelo teste de Kolmogorov–Smirnov (KS) univariado entre dados reais e sintéticos.

Diferenças de escala e centralidade. Para variáveis temporais/categóricas codificadas numericamente, as médias sintéticas divergiram das reais (e.g., Ano: real 2015,87 vs. sintético 2012,65; Mês: 6,54 vs. 2,69). Em variáveis ambientais, observaram-se compressões de escala: DBO (mg/L) reduziu a média de 16,40 (real) para 8,39 (sintético) e o desvio-padrão de 14,18 para 7,10; Turbidez (UNT) reduziu de 36,90 para 3,08 e o desvio-padrão de 78,99 para 5,28. A taxa de Coliformes apresentou queda expressiva de média ($1,83 \times 10^5$ para $1,39 \times 10^4$) e de dispersão.

Teste KS univariado O KS apontou diferenças estatisticamente significativas ($p < 0,001$) entre distribuições reais e sintéticas para todas as variáveis avaliadas (estatística KS variando, por exemplo, de 0,26 em Condutividade até $\sim 0,68$ em Ano, DiaSem e Turbidez). Esses resultados indicam que, no estado atual, a GAN não reproduz adequadamente as caudas e os regimes extremos do conjunto, notadamente para indicadores críticos de qualidade da água (Turbidez, Coliformes, DBO) e para os eixos temporais.

Efeito prático para *data augmentation* Do ponto de vista de uso em modelos preditivos de qualidade da água, a geração atual favorece amostras moderadas e sub-representa eventos de alta magnitude (picos de poluição, episódios de turbidez elevada). Tal compressão de variância pode enviesar modelos supervisionados ao atenuar a sensibilidade a eventos raros, porém relevantes para gestão ambiental.

4.5. Implicações para a avaliação da qualidade da água

Dois achados são centrais: (i) a GAN aprendeu padrões médios em variáveis contínuas menos assimétricas (pH, Temperatura, OD, Con-

ductividade apresentou deslocamento moderado), mas (ii) falhou em reproduzir caudas pesadas e a sazonalidade/estrutura temporal implícita. Em aplicações de qualidade da água, onde limiares regulatórios e ocorrências extremas são determinantes, a validade do *augmentation* depende criticamente de capturar tais caudas.

4.6. Limitações e caminhos de melhoria

Os resultados orientam ajustes metodológicos específicos para dados ambientais tabulares:

1. **Pré-processamento:** aplicar transformações *log*/Box–Cox em variáveis com caudas pesadas (Coliformes, Turbidez, DBO, Condutividade) e reescalar para faixas comparáveis; codificar tempo de forma informativa (e.g., seno/cosseno para mês/semana), evitando que a GAN colapse para anos iniciais.
2. **Arquitetura:** substituir a GAN padrão por **WGAN-GP** (métrica Wasserstein com penalidade de gradiente) ou modelos **tabulares** como *CTGAN*/*TVAE*, que lidam melhor com mistura de escalas e multimodalidade.
3. **Condicionamento:** empregar **cGAN** condicionada por estações/épocas (mês, semana) ou por regimes hidrológicos, permitindo que o gerador produza distribuições específicas por contexto.
4. **Restrições e pós-processamento:** impor *hard ranges* (e.g., $0 \leq$ Coliformes, $0 \leq$ Turbidez), checagens físico-químicas (faixas plausíveis de pH e OD) e *rejection sampling* para recompor caudas.
5. **Validação:** além do KS univariado, avaliar *dependências* (correlações, copulas), métricas multivariadas (e.g., Fréchet/Wasserstein), e, sobretudo, **efeito em modelos downstream** (treinar um preditor com e sem dados sintéticos e comparar desempenho fora da amostra).

4.7. Síntese

Em síntese, a GAN treinada produziu amostras coerentes em regimes centrais, porém com compressão de variância e sub-representação de extremos, levando a divergências significativas segundo o teste KS em todas as variáveis. Para que o *data augmentation* contribua efetivamente para análises e previsões de qualidade da água, são recomendados: transformações adequadas, condicionamento temporal, arquiteturas robustas a caudas e uma validação orientada ao uso final (modelo preditivo e indicadores regulatórios).

4.8. Comparação entre dados reais e sintéticos

A Tabela 2 resume as estatísticas descritivas principais (média e desvio padrão) das variáveis ambientais reais em comparação às geradas pela GAN. Observa-se que variáveis como pH e temperatura mantiveram valores próximos, enquanto indicadores críticos de qualidade da água (DBO, Coliformes, Turbidez) apresentaram redução significativa de magnitude e dispersão.

Tabela 2: Estatísticas descritivas (média e desvio-padrão) para dados reais e sintéticos

Variável	Média (Real)	Média (Sint.)	Desvio-padrão (Real)	Desvio-padrão (Sint.)
DBO (mg/L)	16.40	8.39	14.18	7.10
pH	7.87	7.42	0.61	0.76
Coliformes (NMP/100mL)	1.83×10^5	1.39×10^4	3.78×10^5	1.71×10^4
Temperatura (°C)	24.65	23.56	3.19	4.94
Fósforo Total (mg/L)	1.03	1.67	0.59	0.69
OD (mg/L)	5.01	9.01	3.93	3.93
Condutividade (µS/cm)	19017.90	25335.79	21090.42	19665.95
Turbidez (UNT)	36.90	3.08	78.99	5.28

A Tabela 3 apresenta os resultados do teste de Kolmogorov–Smirnov (KS) entre os dados reais e sintéticos. Em todas as variáveis, as diferenças foram estatisticamente significativas ($p < 0.001$), indicando que a distribuição dos dados sintéticos diverge das reais, especialmente em variáveis com caudas pesadas.

Tabela 3: Resultados do teste de Kolmogorov–Smirnov (KS) para comparação entre dados reais e sintéticos

Variável	Estatística KS	p-valor
DBO (mg/L)	0.411	< 0.001
pH	0.430	< 0.001
Coliformes (NMP/100mL)	0.400	< 0.001
Temperatura (°C)	0.289	< 0.001
Fósforo Total (mg/L)	0.478	< 0.001
OD (mg/L)	0.450	< 0.001
Condutividade (µS/cm)	0.261	< 0.001
Turbidez (UNT)	0.682	< 0.001

Os resultados confirmam que, embora a GAN consiga aproximar médias em algumas variáveis contínuas, há compressão de variância e sub-representação de eventos extremos, reduzindo a utilidade dos dados sintéticos para capturar padrões críticos de qualidade da água.

5. Considerações Finais

Este trabalho apresentou a aplicação de redes adversariais generativas (GAN) como estratégia de *data augmentation* para dados de qualidade da água. A metodologia contemplou desde a etapa de coleta, limpeza e análise exploratória dos dados históricos fornecidos pelo INEA, até a construção, treinamento e avaliação de uma arquitetura GAN capaz de gerar amostras sintéticas

com múltiplos parâmetros físico-químicos e microbiológicos.

Os resultados obtidos demonstraram que a GAN foi capaz de reproduzir, em maior ou menor grau, a distribuição de variáveis ambientais relevantes, como pH, condutividade, fósforo total e oxigênio dissolvido. Embora algumas variáveis tenham apresentado divergências significativas em relação aos dados reais, evidenciadas pelo teste de Kolmogorov–Smirnov, outras mantiveram consistência estatística próxima ao conjunto original, reforçando o potencial da abordagem para complementar séries temporais com lacunas ou descontinuidades.

A utilização de dados sintéticos abre novas perspectivas para pesquisas em monitoramento da qualidade da água, sobretudo em cenários onde a coleta contínua é onerosa ou sujeita a falhas operacionais. Além disso, os modelos gerados em formatos reproduzíveis permitem que outros grupos de pesquisa validem e estendam os experimentos apresentados, ampliando a aplicabilidade da técnica.

Como limitação, destaca-se que o desempenho da GAN foi sensível ao tamanho reduzido do conjunto de dados original, bem como à variabilidade inerente aos parâmetros ambientais. Recomenda-se, em trabalhos futuros, a integração de conjuntos de dados de diferentes fontes e escalas temporais, assim como a avaliação de arquiteturas generativas mais avançadas, como *Wasserstein GANs* ou modelos condicionais (*cGANs*), que podem melhorar a qualidade das amostras geradas.

Em síntese, este estudo reforça a relevância do uso de técnicas de inteligência artificial na área ambiental, apontando as GANs como uma alternativa promissora para mitigar os desafios de escassez e descontinuidade de dados no monitoramento da qualidade da água.

Agradecimentos

Os autores agradecem ao Centro Federal de Educação Tecnológica Celso Suckow da Fonseca pelo fornecimento de bolsa de iniciação científica, possibilitando a realização deste estudo. Além do apoio da FAPERJ, do CNPq e da CAPES.

Referências

Creswell, Antonia, Tom White, Vincent Dumoulin, Kai Arulkumaran, Biswa Sengupta & Anil A. Bharath. 2018. Generative adversarial networks: An overview. *IEEE*

Signal Processing Magazine 35(1). 53–65.
 [10.1109/MSP.2017.2765202](https://doi.org/10.1109/MSP.2017.2765202)

Gil, Antonio Carlos. 2002. *Como Elaborar Projetos de Pesquisa*. Atlas

Goodfellow, Ian, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville & Yoshua Bengio. 2014. Generative adversarial nets. Em *Advances in neural information processing systems*, vol. 27, Curran Associates, Inc.

Mauricio, Dannylo Cardoso, Jader Lugon Jr, André Merlo, Mayara Omai, Pedro Henrique González, Raphael Guerra, Wagner Telles & Diego Brandão. 2025. Application of machine-learning techniques for water quality assessment in coastal environments: A case study of the jacarepaguá lagoon system at rio de janeiro/br. Em *International Conference on Computational Science and Its Applications*, 295–306. Springer

dos Santos, Mariana Rodrigues. 2014. EVOLUÇÃO TEMPORAL DA EUTROFIZAÇÃO NO COMPLEXO LAGUNAR DE JACAREPAGUÁ. 

Shashikala, B., S. Ramesh & A. Kumar. 2025. Gan-based data augmentation for iot-enabled water quality monitoring systems. *Environmental Science: Advances* 4(6). 817–823

Zhang, C., Q. Liang, W. Wang & X. Wang. 2020. Reconstruction of sea level fields in the north sea using generative adversarial networks. *Journal of Marine Systems* 210. 103363